

1. 核心想法

现在的方法不是直接做异常检测，也不是把 tracking 后的视频喂给模型。

我们冻结 Qwen3VL 的视觉编码器，只在 ViT 输出 token 后面训练一个很小的 `objectness head`。这个 head 学习判断：

每个视觉 token 是否属于前景对象。

然后把高 objectness 的相邻 token 聚合起来，得到对象级 token 区域。

2. 方法 Pipeline

```
原始视频帧
↓
Qwen3VL visual encoder, 冻结不训练
↓
视觉 token 特征 + token 空间坐标
↓
轻量 post-ViT objectness head
↓
每个 token 得到 objectness score
↓
筛选 high-objectness tokens
↓
连通域 / 平滑密度图
↓
对象级 token 区域
```

推理时输入只有原始 RGB 视频帧，不输入 tracking、PKL 或检测框。

3. 训练监督方式

训练阶段使用 NWPU 的 tracking PKL，但 PKL 只作为离线监督标签，不作为模型输入。

具体做法：

1. 从视频中采样连续帧，当前 quick run 使用 16 帧。
2. 帧间隔约 0.08s，不超过 1s。
3. 用冻结的 Qwen3VL visual encoder 提取每帧视觉 token。
4. 把 PKL 中的人/车等目标框映射到 token 网格。
5. 落在目标框附近的 token 标为 object token，其余 token 标为 background。
6. 只训练一个轻量 MLP head 做 token-level 二分类。

Head 结构：

token feature: 4096 dim
token coord: x, y, t

[token feature + coord]

- LayerNorm
- Linear + GELU
- Linear + GELU
- Linear
- objectness logit

4. 可视化结果

下面的图是新的细轮廓 objectness density 可视化。它不是 detector box，也不是 tracking 输出，而是把 token-level objectness score 平滑后叠加在原始帧上。

4.1 近景行人/骑车人

模型能在行人和骑车人附近形成连续响应。



4.2 远距离小目标

模型能响应远处小人，但也会把长椅、树影等背景结构误认为对象。




4.3 多目标/远处聚集区域

高 objectness token 会在局部对象区域形成细轮廓，但仍存在人群粘连和背景误响应。



4.4 车辆/边界目标

模型对显著移动目标有响应，但边缘和高对比背景仍可能被激活。



5. 当前结论

目前可以汇报的结论：

1. **可行性成立**：冻结 Qwen3VL visual encoder，只训练 post-ViT objectness head，可以把部分视觉 token 聚合到对象区域。
2. **推理阶段不需要 tracking**：tracking PKL 只用于训练监督，不作为模型输入。
3. **近景对象效果较好**：行人、骑车人等前景对象能形成较连续响应。
4. **小目标和复杂背景仍是问题**：远处小人、树影、长椅、道路边缘容易误响应或粘连。
5. **还不能直接 claim 压缩有效**：目前验证的是 token 聚合能力，下一步才是把 predicted object tokens 接入 token compression。

6. 下一步计划

短期计划：

1. 扩大 NWPU 训练视频数量，优先选择对象多、尺度变化大的视频。
2. 增加 temporal consistency loss，让相邻帧同一对象的 token 响应更稳定。

3. 加入 background hard negative, 减少长椅、树影、道路边缘误响应。
4. 在全量 NWPU 上跑 token 聚合质量统计。
5. 如果对象聚合稳定, 再替代 tracker sidecar, 接入对象级 token compression。

最终目标:

让模型自己从原始视频帧中聚合出对象 token, 再对背景 token 强压缩、对象 token 轻压缩, 从而实现不依赖 tracking 输入的对象级视频 token 压缩。