

O-VAD Token Compression 组会阶段报告

更新时间：2026-05-26

当前口径：ShanghaiTech test-only transductive/debug 数据，用于方法验证和组会讨论，不作为 strict no-leakage benchmark claim。

目录

1. 当前结论
2. O-VAD post-ViT token compression
3. R244 ShanghaiTech Qwen-cache Object Head
4. Token Pruner-Merge 诊断与当前改进
5. 当前文档结构与组会叙事

1. 当前结论

1. O-VAD 证明了一个基本事实：在 Qwen3VL post-ViT token 上做中等强度压缩是可行的。2.5MP 输入下，保留 70% visual tokens 时 accuracy 从 full-token 的 0.902 到 0.925；保留 50% tokens 时仍有 0.910。
2. 过强压缩会破坏 O-VAD 判断。保留 20% tokens 时 accuracy 降到 0.669，说明 VAD 不是可以任意剪 token 的任务。
3. R244 object head 已经达到可用前端水平：best epoch 18 的 AP 为 0.9252，F1@0.5 为 0.8550，Recall@0.5 为 0.8505。
4. 旧的 connected-component object pooling 会破坏对象覆盖率，尤其在密集人群场景中会把多人粘连或漏掉小目标。
5. 新增的 `object_body_pooled` 用 objectness seed 做 body-support 扩张，在 object-rich 样本上显著提升 teacher object coverage：从旧 `object_pooled` 的 0.8686 提升到 0.9714。

2. O-VAD post-ViT token compression

O-VAD 阶段的目标不是训练新的 object head，而是验证：

```
O-VAD triplet visual evidence
-> Qwen3VL image encoder
-> post-ViT visual tokens
-> panel-aware token scoring / pruning
-> Qwen3VL text answer
```

这里的输入是 O-VAD triplet 图像，通常包含：

- global scene context：全局场景。
- object-focused region：对象相关区域。
- trajectory/action cue：轨迹或动作线索。

压缩方法是在 Qwen3VL ViT 输出之后、LLM 输入之前，对 visual tokens 做 post-ViT pruning。selector 使用已有 objectness / panel-aware scoring，保留高分 tokens，删除低分 visual tokens。这个阶段的压缩发生在 LLM boundary，不能减少 Qwen3VL ViT 编码本身的计算，但能验证视觉 token 是否存在冗余。

2.5MP O-VAD 压缩结果：

Method	Retention	Visual tokens	Compression	Accuracy	Abnormal Acc	Normal Acc	Mean sec
Full tokens	100%	2576	1.00x	0.902	-	1.000	7.544
Post-ViT prune r=0.70	70%	1803	1.43x	0.925	0.921	1.000	6.794
Post-ViT prune r=0.50	50%	1288	2.00x	0.910	0.906	1.000	6.367
Post-ViT prune r=0.20	20%	515	5.00x	0.669	0.669	0.667	6.150

这个结果说明：

- O-VAD 在 50%-70% retention 区间对 token pruning 比较鲁棒。
- 20% retention 已经过强，会明显损害 abnormal / normal 判断。
- O-VAD 的成功依赖预构造 triplet 面板；它还不是 full-frame Qwen token 空间里的 object-level aggregation。

O-VAD 参考指标：

Setting	AUC	E-Acc	O-Acc
O-VAD	0.591	0.858	0.906

含义：

- AUC：整体异常排序能力。
- E-Acc：event-level / evidence-level 判断准确率。
- O-Acc：object-level 定位或对象类别相关判断准确率。

当前 ObjPruneMerge 方向要追的不是单纯 frame-level AUROC，而是：

压缩 token 后仍能保留异常对象证据；
能够说明异常 object 是谁；
对象级定位不能明显低于 O-VAD。

3. R244 ShanghaiTech Qwen-cache Object Head

R244 使用已经人工审核过的 R234 accepted/weak 数据，不重新跑 Qwen3VL ViT，只读取已有 Qwen token cache 训练 object head。

Object head 的来源可以概括为：

ShanghaiTech test-only curated frames
-> offline teacher / reviewed pseudo labels
-> map object boxes or masks to Qwen token grid
-> token-level labels
-> frozen Qwen post-ViT token cache
-> train object head on tokens

也就是说，object head 不是直接看原图训练的检测器，而是一个作用在 Qwen3VL post-ViT token 上的小头。离线 teacher 和人工筛选只用于构造训练标签，训练完成后 runtime 不再输入 YOLO box、YOLO label、teacher heatmap 或 crop。

训练标签主要包括：

- `y_obj`：每个 Qwen token 是否属于可见对象。
- `y_cls`：前景 token 的对象类别，目前重点是 person / foreground object。
- `y_inst`：token 属于哪个单帧 object instance，用于 grouping 监督。
- `y_merge`：token 是否适合作为 pooling 高权重位置的弱标签。

训练输入：

```
[Qwen post-ViT token embedding; normalized x/y]
```

输出：

```
objectness
class logits
group embedding
merge importance
```


Object head 指标：

Checkpoint	AP	P@0.5	R@0.5	F1@0.5	Class Acc
R244 best epoch 18	0.9252	0.8596	0.8505	0.8550	0.9173
epoch 20	0.9252	0.8365	0.8647	0.8504	0.9096
epoch 30	0.9137	0.8554	0.8508	0.8531	0.9058
epoch 36	0.8819	0.8713	0.8094	0.8392	0.9065

R209 full-grid audit gallery：

K:/Paperdata/token_pruner_merge/data_objprunemerge/object_head/r244_shanghai_r234_qwencache_objhead_big100_v1/r209_best_visual_audit_48/index.html

Object head only 诊断图：



这张图的作用是判断 object head 自身是否可用。每一格含义如下：

- `raw`：原始帧。

- `objectness heat`: object head 预测的对象/前景热力图。
- `top32 objectness source`: 按 objectness 分数选出的 top-32 原始 token 位置。
- `merge-importance heat`: merge importance 预测热力图。
- `person-class prob heat`: person 类别概率热力图。
- `top32 objectness + merge source`: 结合 objectness 与 merge importance 后的 top-32 token 位置。

诊断结论:

- `objectness heat` 能覆盖人群、独立行人和前景人物, 说明 object head 有可用信号。
- `top32 objectness source` 看起来较好, 但它只是 patch-level top-k, 不是 object-level merge。
- `merge-importance heat` 背景响应偏高, 当前不适合作为主 pooling 权重。
- 后续 Pruner-Merge 应以 objectness 为主, merge importance 只作为弱辅助。

4. Token Pruner-Merge 诊断与当前改进

4.1 旧方法为什么失败

旧 R210 方法主要是:

```
objectness proposal
-> connected component
-> objectness + merge weighted pooling
```

这个方法在可视化上暴露出三个问题。第一, 密集人群容易被 connected component 粘成少数大块, 导致“聚合对象”不再对应单个人。第二, 小目标或分散行人容易被 top connected groups 漏掉。第三, merge importance 当前背景响应偏高, 如果强行参与 pooling, 会把背景 token 混进 object token。

因此, 旧方法虽然能产生 object-level token, 但它不是稳定的“整个人”聚合。它更像把 objectness 连通区域粗暴压成 token, 容易在 crowded scene 中丢失对象边界。

之前试过的 Pruner-Merge 策略主要有几类:

- `top_objectness_patch`: 直接选 objectness 最高的 patch token。它覆盖率高, 但本质仍是 patch-level top-k, 不会把整个人聚成一个 object token, 也不能自然表示对象级异常。
- `object_representative`: 每个候选对象只取一个代表 token。它压缩很强, 但容易只拿到头部、躯干或局部高响应点, 丢掉完整身体和动作信息。
- `object_pooled` 旧方法: 先用 objectness threshold / top-k 得到 proposal, 再做 connected component, 然后对每个连通域 pooling。它在稀疏场景可用, 但在人群密集场景会把多人粘成一个大对象, 或者漏掉边缘小目标。
- `object_pooled_scene / boundary / motion`: 在 object token 之外加入规则式 scene、boundary、motion tokens。问题是这些 token 没有经过 VAD 目标对齐, scene 和 motion 很容易选到背景、光照变化或地面纹理, 导致 residual score 被噪声主导。

这些方法的 VAD 指标差, 核心原因不是 object head 完全没学到对象, 而是后面的 token 聚合和 frame-level residual scoring 没有对齐 VAD 目标。具体说: 第一, 旧 pooling 没有保证一个输出 token 对应一个完整对象; 第二, 规则式 scene / boundary / motion token 不一定是异常证据; 第三, 当前 smoke 使用的是 normal feature residual, 不是 object-level anomaly scorer, 所以 object coverage 的提升不能自动转成 frame-level AUROC/AP。

4.2 新的 object_body_pooled 方法

基于 object head only 图中第 2、3、6 面板的观察：

- `objectness heat` 能覆盖人体。
- `top32 objectness source` 能抓住目标区域。
- `objectness * merge` 也能提供部分 object support, 但 merge 不能强用。

新的 Pruner-Merge 改成：

```
top objectness token as seed
-> vertical body-support expansion
-> soft pooling over full body support
```

代码位置：

```
F:/keyan/token_pruner_merge/exps/20260522/scripts/build_r210_objprunemerge_feature_
variants.py
```

新增 runtime variants：

```
object_body_pooled
object_body_pooled_top_objectness_backfill
```

核心变化：

```
旧方法: connected component -> pool
新方法: objectness seed -> body-shaped expansion -> soft pool
```

Pooling 权重：

```
w_i = softmax(2.5 * objectness_i + 0.15 * merge_i)
```

这保证 objectness 是主信号，merge importance 只作为弱辅助。

具体聚合过程如下：

1. 先在 full-frame Qwen token grid 上计算每个 token 的 objectness。
2. 从 objectness 高的位置选 seed，并用非极大抑制避免多个 seed 全部落在同一个人身上。
3. 对每个 seed 生成一个 body-support 区域。这个区域不是简单连通域，而是围绕 seed 做更符合人体形状的扩张，优先覆盖竖直方向和邻近高 objectness token。
4. 在 body-support 内部计算 pooling 权重，主要看 objectness，merge importance 只作为弱辅助。
5. 对 body-support 内的原始 Qwen tokens 做加权 pooling，得到一个 object token。

因此，`object_body_pooled` 的目标不是选几个最高分 patch，而是让一个输出 token 尽量代表一个完整人体或前景对象。它仍然是 runtime 方法：输入只有 Qwen tokens 和 object head 输出，不使用 teacher box。

4.3 两张图的关系与 coverage 验证

第一张图是 object head 的诊断图，回答的问题是：


Qwen post-viT token 上，哪里像人或前景对象？
哪些 token 可以作为 object seed？
merge importance 是否可靠？

第二张图是 `object_body_pooled` 的 Pruner-Merge 结果图，回答的问题是：

基于 objectness seed 和 body-support expansion，
最终每个输出 object token 是从哪些原始 Qwen tokens 聚合来的？

也就是说，第一张图是“信号来源”，第二张图是“聚合结果”。第二张图不是重新检测对象，也不是 YOLO teacher；它是把第一张图里可靠的 objectness / top-objectness 信号变成 runtime object token 的结果。

`object_body_pooled` 可视化：



这张图中：

- 第一行左侧是原始帧，第一行中间是合成 evidence heat。
- 第二行是 `o_t object aggregation`，也就是 object token 聚合结果。

- 第二行第三列是 `o_t object aggregation source support`，表示每个输出 object token 从哪些原始 Qwen tokens 聚合而来。它不是 embedding 本身，而是 token pooling 的来源区域。
- 后面几行的 scene / boundary / motion 为空，是因为这个示例重点展示 object-body pooling，不展示规则式 O/S/B/M 拼接。

Object-rich coverage 结果如下。在 object-rich 样本上，用 teacher token masks 评估 runtime source tokens 是否覆盖 teacher objects：

Variant	Teacher object coverage
top_objectness_patch	0.9657
object_pooled 旧方法	0.8686
object_body_pooled 新方法	0.9714
teacher_upper_bound	0.9981

这个结果说明：

- 旧 connected-component object pooling 确实把对象覆盖率压坏了。
- `object_body_pooled` 已经接近 top-objectness，并明显优于旧 `object_pooled`。
- 它比纯 top-objectness 更符合“聚合整个人”的目标，因为每个输出 token 是 body-support group 的 pooled token，而不是单个 patch token。

5. 当前文档结构与组会叙事

这份报告现在按一条主线组织：

1. 第 1 节给出结论：O-VAD 中等比例 token compression 可行，R244 object head 可用，旧 pooling 有问题，body pooling 改善 object coverage。
2. 第 2 节介绍 O-VAD：它是 triplet 图像上的 post-ViT token pruning，说明 `50%-70%` retention 可以保留大部分判断能力，但它还不是 full-frame object-level aggregation。
3. 第 3 节介绍 object head 如何得到：它不是图像检测器，而是在 Qwen post-ViT token 上训练出来的 token-level objectness / class / grouping / merge head。
4. 第 4 节介绍 Pruner-Merge：先说明旧 connected-component 和规则式 O/S/B/M 为什么 VAD 指标差，再说明 `object_body_pooled` 如何用 objectness seed 聚合整个人。

组会时建议按这个逻辑讲：

```
O-VAD 说明 post-ViT token 有可压缩空间
-> 但 O-VAD 依赖 triplet 面板，不是 full-frame runtime 方法
-> 因此我们转向 Qwen token 空间里的 object head
-> object head 已经能给出可用 objectness
-> 旧 connected-component pooling 会破坏整个人覆盖
-> object_body_pooled 用 objectness seed + body-support expansion 修正这个问题
```

当前可以 claim：

```
Objectness-seeded body pooling is a better runtime object-token aggregation
mechanism than connected-component pooling on object-rich ShanghaiTech debug
samples.
```

暂时不要 claim：

ObjPruneMerge 已经提升严格 ShanghaiTech benchmark。